第 2 章模型评估与选择 练习题参考答案

习题 2.1 数据集包含 1000 个样例，其中 500 个正例，500 个负例。将其划分为包含 70%样例的训练集和 30%的测试集用于留出法评估，试估算共有多少种划分方法。

答：排列组合问题。
训练/测试集的划分要尽可能保存数据分布一致
那么训练集中应该包括 350 个正例和 350 个反例，剩余的作测试集，那么划分方式应该有 $C_{500}^{300} \cdot C_{500}^{300}$种。

习题 2.2 假设学习算法所产生的模型按照类别出现的概率进行预测，将新样例预测为训练样例数较多的类别（训练样例数相同时进行随机猜测），考虑在一下两种情况下交叉验证法和留一法的差异，并给出用 10 折交叉验证法和留一法分别对错误率进行评估所得的结果。
1.假设数据集包含 100 个样例，其中正负例各一半。
2.假设数据集包含 100 个样例，其中正例 51 个，负例 49 个。

答：情况 1：假设数据集包含 100 个样例，其中正负例各一半。

1. 10 折交叉验证错误率
   采用分层抽样，每个数据集都是正负例各一半，训练样例数相同时随机猜测，故期望错误率是 50%；
2. 留一法（LOO）错误率
   每次留出一个样例作为测试集。① 若留出的是负例，则训练集为 50 正例+49 负例，正例样本占多数，故将所有样本预测为正例，剩余的测试集为 1 个负例，预测错误；② 若留出的是正例，则训练集为 50 负例+49 正例，负例样本占多数，故将所有样本预测为负例，剩余的测试集为 1 个正例，预测错误；故留一法的期望错误率为 100%。

情况 2：数据集 100 个样例（正例 51 个，负例 49 个，正例数略多）

1. 10 折交叉验证法：每个数据集都是正例比负例多，所以预测结果均为正例，故期望错误率为 49%；
2. 留一法：① 若留出的是负例，则训练集为 51 正例+48 负例，正例样本占多数，故将所有样本预测为正例，剩余的测试集为 1 个负例，预测错误；② 若留出的是正例，则训练集为 50 正例+49 负例，正例样本占多数，故将所有样本预测为正例，剩余的测试集为 1 个正例，预测正确；故留一法的期望错误率为：

$$\frac{49}{100} \times 100\% + \frac{51}{100} \times 0\% = 49\%$$

故 10 折交叉验证法和留一法的错误率均为 49%.

习题 2.3 在某个西瓜分类任务的验证集中，共有 10 个样例，其中有 3 个示例的类别标记为“1”，表示该示例是好瓜；有 7 个示例的类别标记为“0”，表示该示例不是好瓜。由于学习方法能力有限，只能产生在验证集上精度为 0.8 的分类器。

1.如果想要在验证集上得到最佳查准率，该分类器应该做出何种预测？此时的查全率和 F1 分别是多少？2.如果想要在验证集上得到最佳查全率，该分类器应该做出何种预测？此时的查准率和 F1 分别是多少？

答：1.追求最佳查准率

-错误预测数：FN+FP=2 已知错误预测数是 2，要让查准率最高，需让 FP 最小（最好为 0），所以错误预测全分配给 FN，即 FN=2，FP=0。

实际/预测	1（好瓜）	0（坏瓜）	合计（实际）
1（好瓜）	TP=1（3-2）	FN=2	3
0（坏瓜）	FP=0（2-2=0）	TN=7（7-0=7）	7

- 查准率（P）：

$$P = \frac{TP}{TP + FP} = \frac{1}{1 + 0} = 1.0\ （FP = 0，\textit{无假正例，查准率达最大值}）$$

- 查全率（R）：

$$R = \frac{TP}{TP + FN} = \frac{1}{3} \approx 0.333$$

- 正确预测数：TP+TN=1+7=8（符合精度 0.8 的要求）

- F1 分数：

$$F1 = \frac{2PR}{P + R} = \frac{2 \times 1 \times \frac{1}{3}}{1 + \frac{1}{3}} = \frac{1}{2} = 0.5$$

2. 追求最佳查全率

实际/预测	1（好瓜）	0（坏瓜）	合计（实际）
1（好瓜）	TP=3（3-0=3）	FN=0（2-2）	3
0（坏瓜）	FP=2	TN=5（7-2=5）	7

- 错误预测数：FN+FP=0+2=2（符合要求，错误预测全分配给 FP，确保 FN=0，无漏判好瓜）

- 查全率（R）：

$$R = \frac{TP}{TP + FN} = \frac{3}{3 + 0} = 1.0\ （FN = 0，\textit{无假负例，查全率达最大值}）$$

- 查准率（P）：

$$P = \frac{TP}{TP + FP} = \frac{3}{3 + 2} = \frac{3}{5} = 0.6$$

- 正确预测数：TP+TN=3+5=8（符合精度 0.8 的要求）
- F1 分数：

$$F1 = \frac{2PR}{P + R} = \frac{2 \times \frac{3}{5} \times 1}{\frac{3}{5} + 1} = \frac{3}{4} = 0.75$$

习题 2.4 假设某数据集包含 8 个样例，其对应的标记和学习器的输出值(从大到小排序)见下表。该任务是一个二分类任务，标记 1 或 0 表示真实标记为正例或负例。学习器的输出值代表学习器对样例是正例的置信度(认为该样例是正例的概率)。

样例	X1	X2	X3	X4	X5	X6	X7	X8
标记	1	1	0	1	0	1	0	0
学习器的输出值	0.81	0.74	0.62	0.53	0.44	0.35	0.25	0.21

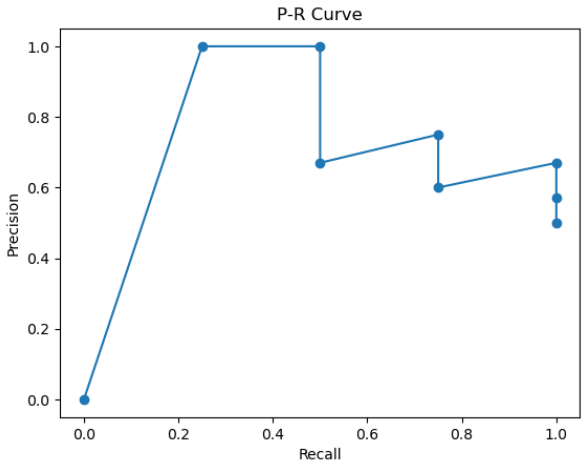
1.计算 P-R 曲线中的每一个端点的坐标并绘图。
2.计算 ROC 曲线中每一个端点的坐标并绘图，计算 AUC(Area Under the ROC Curve，曲线下的面积)。

答：1. P-R 曲线端点坐标计算与分析
P-R 曲线的端点由“不同阈值下的查准率（P）和查全率（R）”确定，需先统计正例数（实际标记为 1 的样例数）：样例 X1、X2、X4、X6，共 4 个正例；负例数为 4 个。

阈值（取学习器输出值)	预测为正例的样例	TP（真正例）	FP（假正例)	查准率 P= TP/(TP+FP)	查全率 R= TP/4（总正例数）	端点坐标 (R, P)
＞0.81	无	0	0	/	0/4	（0, 0）
0.74～0.81	X1	1	0	1/1=1	1/4=0.25	（0.25, 1）
0.62～0.74	X1，X2	2	0	2/2=1	2/4=0.5	(0.5, 1)
0.53～0.62	X1，X2，X3，	2	1(X3 是负例)	2/3	2/4	(0.5, 0.67)
0.44～0.53	X1，X2，X3，X4	3	1	3/4=0.75	3/4	(0.75, 0.75)
0.35～0.44	X1，X2，	3	2(X3，X5	3/5	3/4	(0.75, 0.6)

	X3，X4，X5		是负例)			
0.25～0.35	X1，X2，X3，X4，X5，X6	4	2	4/6	4/4	(1, 0.67)
≤0.25	All	4	4	4/8	4/4	(1, 0.5)

根据 P 和 R 的计算值描点连线，P-R 曲线如下：



2. ROC 曲线端点坐标、绘图与 AUC 计算

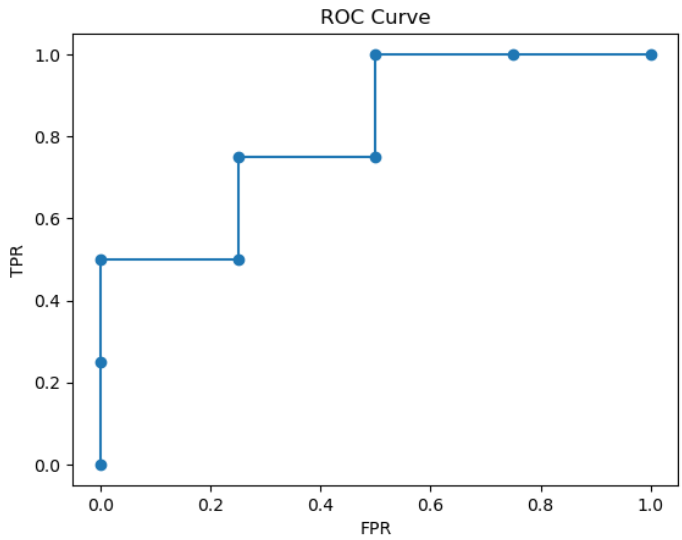
ROC 曲线的端点由“不同阈值下的假正例率（FPR）和真正例率（TPR）”确定，其中：

- 真正例率 TPR = TP/4（总正例数）
- 假正例率 FPR = FP/4（总负例数）

阈值	预测为正例的样例	TP	FP	TPR=TP/4	FPR=FP/4	端点坐标 (TPR, FPR)
＞0.81	无	0	0	0	0	(0, 0)
0.74～0.81	X1	1	0	0.25	0	(0, 0.25)
0.62～0.74	X1，X2	2	0	0.5	0	(0, 0.5)
0.53～0.62	X1，X2，X3，	2	1	2/4	1/4	(0.25, 0.5)
0.44～0.53	X1，X2，X3，X4	3	1	3/4	1/4	(0.25, 0.75)
0.35～0.44	X1，X2，X3，X4，X5	3	2	3/4	2/4	(0.5, 0.75)
0.25～0.35	X1，X2，X3，X4，	4	2	4/4	2/4	(0.5, 1)

	X5，X6					
≤0.25	All	4	4	4/4	4/4	(1, 1)

ROC 曲线以 TPR 为纵轴，FPR 为横轴，绘图如下：



所以曲线下的面积 AUC 为：

$$AUC = 1 - \ell_{rank} = 1 - \frac{1}{m_+ m_-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} \left(\mathbb{I}\big(f(x^+) < f(x^-)\big) + \frac{1}{2} \mathbb{I}\big(f(x^+) = f(x^-)\big) \right)$$

$$= 1 - \frac{1}{4 \times 4} \times 3 = 0.8125$$